Trabajo módulo IV

Procesamiento de datos de calidad del aire de Madrid.



Alexander Balseiro Brian Ferrol Álvaro Cerrato Ángel Rivas







Descripción de caso de uso.

MEDICIÓN DE CALIDAD DEL AIRE DE MADRID

- Analizar los datos proporcionados por ayuntamiento de Madrid.
- Disponibilizar los datos de manera óptima para:
 - Consulta real-time de la calidad del aire por parte de usuario final.
 - Consulta analítica por parte de los analistas de la Comunidad de Madrid.







Descripción de caso de uso.



Consulta del estado del aire en el momento.



Ver principales indicadores abiertos por horario y ubicación geográfica.





Datos disponibles: Actualización cada 1 hora

- Geo Espaciales: Temporales: Magnitudes de calidad:
 - Provincia

Año

Municipio

Mes

Estación

- > Día
- Hora

- UV: radiación ultravioleta.
- DV: dirección del viento.
- VV: velocidad del viento.
- RS: radiación solar.

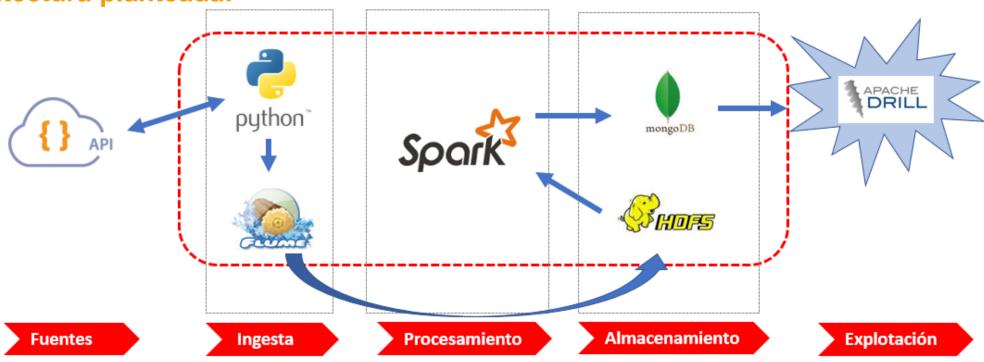
- HR: humedad relativa.
- PB: presión barométrica.
- T: temperatura.
- P: precipitación.





Arquitectura y flujo de datos

Arquitectura planteada:







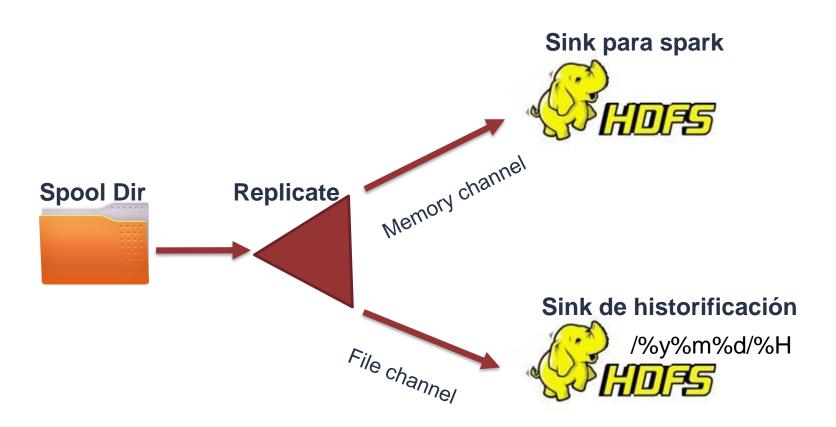


```
# API request:
url = "http://www.mambiente.madrid.es/opendata/horario.csv"
while True:
    s=requests.get(url).content
    c=pd.read csv(io.StringIO(s.decode('utf-8')), sep=';')
    c['H01'] = c.V01+c.H01.map(str)
    c['H02'] = c.V02+c.H02.map(str)
    c['H03'] = c.V03+c.H03.map(str)
                                            drop_columns = {'V01', 'V02', 'V03', 'V04', 'V05', 'V06' \
    c['H04'] = c.V04+c.H04.map(str)
                                            , 'V07', 'V08', 'V09', 'V10', 'V11', 'V12', 'V13', 'V14'\
    c['H05'] = c.V05+c.H05.map(str)
                                            , 'V15', 'V16', 'V17', 'V18', 'V19', <u>'</u>V20', 'V21', 'V22', \
    c['H06'] = c.V06+c.H06.map(str)
                                            'V23', 'V24'}
    c['H07'] = c.V07+c.H07.map(str)
                                            c.drop(columns=drop columns, axis=1)
                                            eventTime = time.strftime("%Y%m%d%H%M")
                                            file name = "airQuality "+eventTime+'.csv'
                                            c.to csv(r'./data/'+file name, sep='\t',encoding='utf-8', index=False)
                                            time.sleep(3600)
```















Procesamiento

```
// Leer la copia del ultimo csv con la medición, las dos fuentes de códigos-estaciones
// y códgios-magintudes.
val aire = spark
    .read
    .option("header", "true").csv("/user/abalserio/Grupal4_Flume/datosSpark/")
val codigo_estaciones = spark
    .read
    .option("header", "true").csv("./src/main/scala/m4/resources/codigo_estaciones.csv")
val codigo_magnitud = spark
    .read
    .option("header", "true").csv("./src/main/scala/m4/resources/codigo_magnitud.csv")
```







Procesamiento

```
val df1 = aire tuning2.select(col("Nombre Estacion"), col(" id").as("Fecha"),
  struct(
    col("PUNTO MUESTREO"),
    col("MAGNITUD NOMBRE"),
    struct(
      col("H01 "),
      col("H24 ")
    ).as("values")
  ).as("info")
).groupBy(
  "Fecha", "Nombre Estacion"
).agg(
  collect list("info").alias("info")
val df2 = df1.select(
  col("Fecha").alias(" id"), struct(col("Nombre Estacion"), col("info")).as("details"))
.groupBy(" id").agg(collect list("details").alias("details"))
```







Procesamiento

```
" id": "2019-04-07 00:00:00",
"details": [
    "Nombre Estacion": "Méndez Álvaro",
    "info": [
        "PUNTO MUESTREO": "28079047 7 8",
        "MAGNITUD NOMBRE": "Monóxido de Nitrógeno",
        "values": {
          "H01 ": "1.0",
          "H02": "1.0",
          "H03": "1.0",
          "H04": "1.0",
          "H05": "1.0",
          "H06": "1.0",
          "H07": "1.0",
          "H08": "1.0",
          "H09": "1.0",
          "H10 ": "1.0",
          "H11": "1.0",
          "H12": "1.0"
        "PUNTO MUESTREO": "28079047 8 8",
        "MAGNITUD NOMBRE": "Dióxido de Nitrógeno",
        "values": {
          "H01 ": "15.0",
         "H02" · "15 0"
```







DETALLES DE ALMACENAMIENTO

■ ¿Por qué mongo?

- Conector con flume y spark.
- Escalable: si se incluyen más provincias se podría escalar.
- Tolerante a fallos.
- Consultas rápidas sobre campos indexados (Fecha, estación, etc),





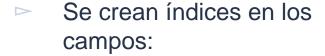


mongoDB

DETALLES DE ALMACENAMIENTO







- _id (fecha)
- Estación
- Magnitud

Se eligió el campo "ESTACION" del tipo "hashed" :

- Es un campo por el que se realizan muchas de las consultas. El datacenter debería estar preparado para soportar consultas de madrid y luego escalar si se abren nuevas localizaciones.
- No es creciente/decreciente.
- Si se incluyen más localizaciones, se abre la posibilidad de escalar.





Almacenamiento

DETALLES DE LA INDEXACIÓN

```
db.users.createIndex({"_id":-1})
         "createdCollectionAutomatically" : false,
         "numIndexesBefore" : 1,
         "numIndexesAfter": 1,
         "note" : "all indexes already exist",
         "ok" : 1
      db.users.createIndex({"details.Nombre_Estacion":1})
         "createdCollectionAutomatically" : false,
         "numIndexesBefore" : 1,
         "numIndexesAfter" : 2,
         "ok" : 1
      db.users.createIndex({"details.info.MAGNITUD_NOMBRE":1})
         "createdCollectionAutomatically" : false,
         "numIndexesBefore" : 2,
42
         "numIndexesAfter" : 3,
         "ok" : 1
44
```

mongoDB

```
db.users.getIndexes()
      "v" : 1,
      "key" : {
      "name" : " id ",
      "ns" : "test.users"
      "v" : 1,
      "key" : {
          "details.Nombre Estacion" : 1
      "name" : "details.Nombre Estacion 1",
      "ns" : "test.users"
          "details.info.MAGNITUD NOMBRE" : 1
      "name" : "details.info.MAGNITUD NOMBRE 1",
      "ns" : "test.users"
```



Almacenamiento – Explotación



QUERYS

SOLO MÉNDEZ ÁLVARO

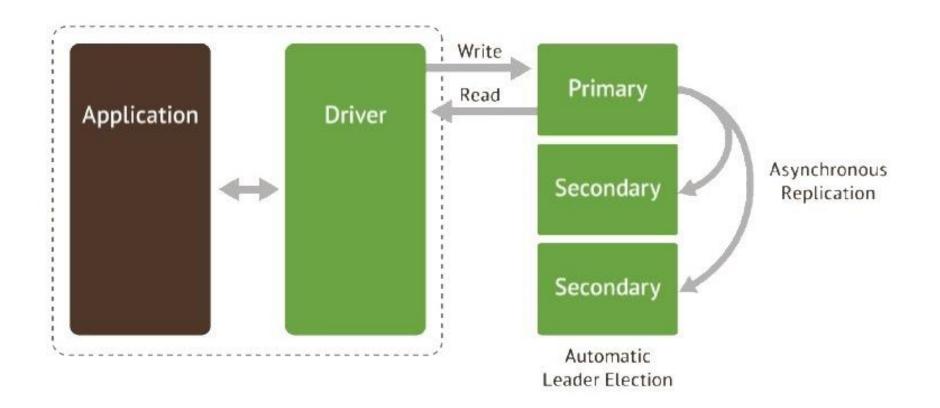
```
"PUNTO_MUESTREO" : "28079047_9_47",
"MAGNITUD NOMBRE" : "Partículas < 2.5 μm",
"values" : {
   "H01 " : "V4.0",
    "H02 ": "V2.0",
           : "V1.0",
           : "V1.0",
          : "V2.0",
           : "V2.0",
    "H07 ": "V3.0",
          : "V2.0",
          : "V2.0",
           : "V1.0",
    "H11 "
           : "V1.0",
    "H12 "
          : "V1.0",
    "H13 "
    "H14 '
    "H15
```

```
"PUNTO_MUESTREO" : "28079047_12_8",
"MAGNITUD NOMBRE" : "Óxidos de Nitrógeno",
"values" : {
    "H01 ": "V17.0",
    "H02 ": "V13.0",
    "H03 " : "V11.0",
            "V8.0",
          : "V7.0",
            "V8.0",
            "V10.0",
    "H08 ": "V13.0",
    "H09 ": "V14.0",
    "H10 " : "V12.0",
    "H11_" : "V9.0",
    "H12 ": "V9.0",
    "H14
    "H15
    "H17
```



Infraestructura

DETALLES LA INFRAESTRUCTURA





Almacenamiento – Explotación



DETALLES DE LA CONEXIÓN MONGO- DRILL

```
1 {
2    "type": "mongo",
3    "connection": "mongodb://localhost:27017/",
4    "enabled": true
5 }
```





Explotación



QUERYS

```
0: jdbc:drill:zk=local> show databases;
      SCHEMA_NAME
  cp.default
  dfs.default
  dfs.root
  dfs.tmp
  information schema
  mongo.db
  mongo.local
  mongo.test
  sys
0: jdbc:drill:zk=local> use mongo.test;
                         summary
  true | Default schema changed to [mongo.test]
1 row selected (0.077 seconds)
0: jdbc:drill:zk=local> show tables;
 TABLE_SCHEMA | TABLE_NAME
  mongo.test
                  data
  mongo.test
                 data2
  mongo.test
                  students
  mongo.test
                  del
  mongo.test
                 users
```







QUERYS











QUERYS

68 69 70	s	emicolon>	from (select uid, fl		id, a.det.Nombre_Estaci rom users u) a;	on Esta	ciones	, flat	ten (a	.det.i	nfo) i	nfo																	
71 72	Fragment	Number of	records written																										
73 74	0_0	151																											
75 76																													
77 78 79 80 81 82	0: jdbc:drill:zk=local> select bid, b.Estaciones, b.P_MUESTREO, b.MAGNITUD, b.val.H01_, b.val.H02_, b.val.H03_, b.val.H04_, b.val.H05_, b.val.H06_, b.val.H08_, b.val.H09_, b.val.H10_,semicolon> b.val.H11_, b.val.H12_, b.val.H13_, b.val.H14_, b.val.H15_, b.val.H16_, b.val.H17_, b.val.H18_, b.val.H19_, b.val.H20_, b.val.H21_, b.val.H22_, b.val.H24semicolon> from (select iid, i.Estaciones, i.info.PUNTO_MUESTREO P_MUESTREO, i.info.MAGNITUD_NOMBRE MAGNITUD, flatten (i.info.values) val)> from users_inf i)b;																												
83	_id		Estaciones	P_MUESTREO	MAGNITUD	H01_	H02_	Н03_	H04_	H05_	Н06_	H07_	н08_	H09_	H10_	H11_	H12_					H17_							
84 85	20190407		C/ Farolillo	28079018_1_38	Dióxido de Azufre	null	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0					null r							
	20190407		C/ Farolillo	28079018_6_48	Monóxido de Carbono	0.4	0.4	0.4	0.4	0.4	0.4	0.4	0.4	0.4	0.4	0.4	0.4					null r							
87	20190407		C/ Farolillo	28079018_7_8	Monóxido de Nitrógeno	6.0	6.0	6.0	6.0	6.0	6.0	6.0	6.0	6.0	6.0	6.0	6.0					null r							
88	20190407		C/ Farolillo	28079018_8_8	Dióxido de Nitrógeno	19.0		19.0	19.0	19.0												null r							
89	20190407		C/ Farolillo	28079018_10_47	Partículas < 10 μm																	null r							
90	20190407	!	C/ Farolillo	28079018_12_8	Óxidos de Nitrógeno	8.0						8.0										null r							
91	20190407		C/ Farolillo	28079018_14_6	Ozono	0.1	0.1		0.1			0.1	0.1									null r							
92 93	20190407		C/ Farolillo	28079018_20_59	Tolueno	8.0	8.0	8.0	8.0	8.0	8.0	8.0	8.0	8.0	8.0	8.0	8.0	null	null	luutt	nutt	null r	IUTTII	nuttli	uuttii	nutt r	nuttlu	ulllu	iuii







PROBLEMAS Y ASPECTOS A MEJORAR

Problemas:

- Generación de json anidados.
- Problemas para acceder a los Arrays con subjsons porque por mucho que replicabamos los pasos de la documentación, no nos funcionaba.
- Consultas de json con Drill.

Aspectos a mejorar:

Poder implementar el indicador del aire debido a que es una función compleja.





KPI: ICA (Indicador de Calidad del Aire)

Sistema para informar sobre la gravedad de los niveles de calidad del aire, en términos entendibles con un resultado numérico que varía de 1 a 150, siendo el valor más alto el de mayores consecuencias.

CONTAMINANTE	VALOR LÍMITE
Dióxido de Azufre (SO2)	VL horario= 125 μg/m3
Dióxido de Nitrógeno (NO2)	VL horario= 200 μg/m3
Partículas (PM10)	VL horario= 50 μg/m3
Ozono (O3)	VL horario=180 μg/m3
Monóxido de carbono (CO)	VL horario=10 μg/m3

Índice	Calidad del Aire	Color Descriptivo
≥ 0 y < 75	Buena	Verde
≥ 75 y <100	Admisible	Amarillo
≥100 y <150	Mala	Rojo
≥ 150	Muy Mala	Violeta

¡Muchas gracias!



Alexander Balseiro Brian Ferrol Álvaro Cerrato Ángel Rivas